Jack

Företagets bakgrund och problem

- Kravkort: Elin på legal/compliance
- Hanterar klagomål. Beslut måste kunna förklaras. Undvik att oskyldiga drabbas.
- Manuell granskning ineffektivt.
  Vår modell halverar arbetsbelastning.
- Kravställning från Legal/Compliance:
  - Förklarbarhet
  - Konsekvent beteende
  - Undvika att oskyldiga drabbas

Jack

Data-insikter och risker

Heatmap / Korrelationsmatris
Här ser vi att target påverkas mest av "contains_off_platfrom", "prev_reports_30d", "account_age_days", "urgency_words". Generellt visar det låg korrelation mellan features vilket indikerar att alla bidrar med information.

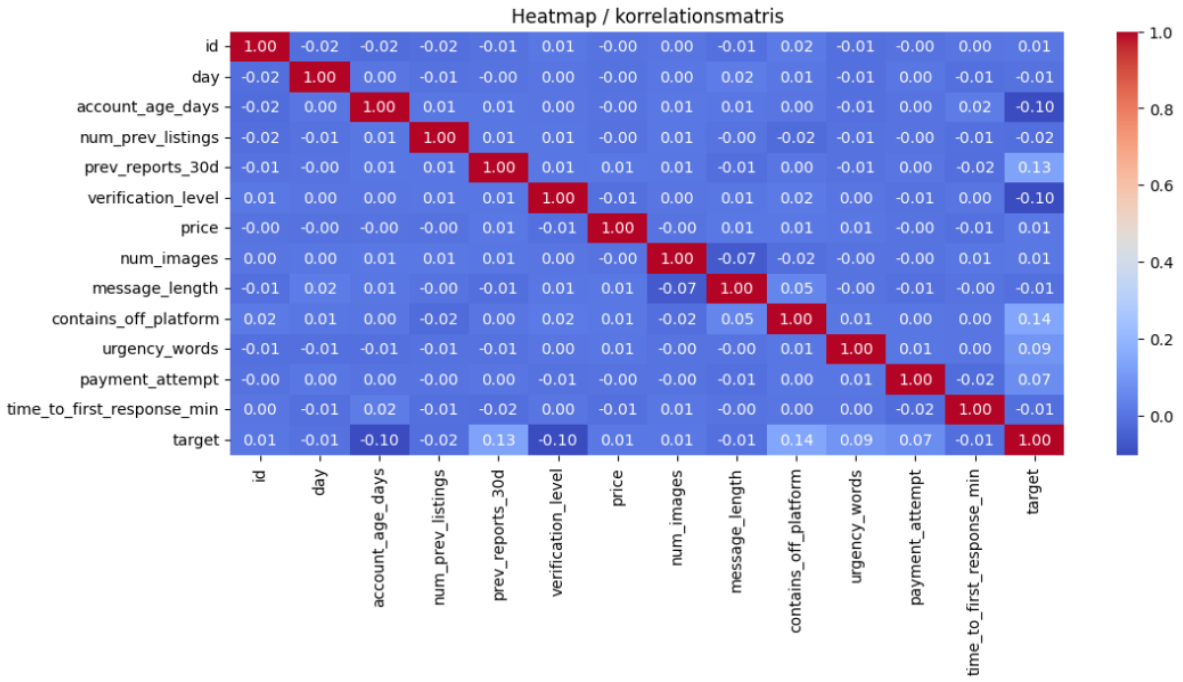

Saknade värden
Numeriska kolumnerna prisfördelning & tid för svar innehöll null. Graferna visar att medianen är bäst för för att hantera saknade värden (imputer strategy). Medianen påverkas inte så mycket av outliers.

Skevt dataset

Endast 10% misstänkta fall, vilket gör att accuracy blir missvisande.
Om modellen säger bedrägeri varje gång blir det ca 90% accuracy.

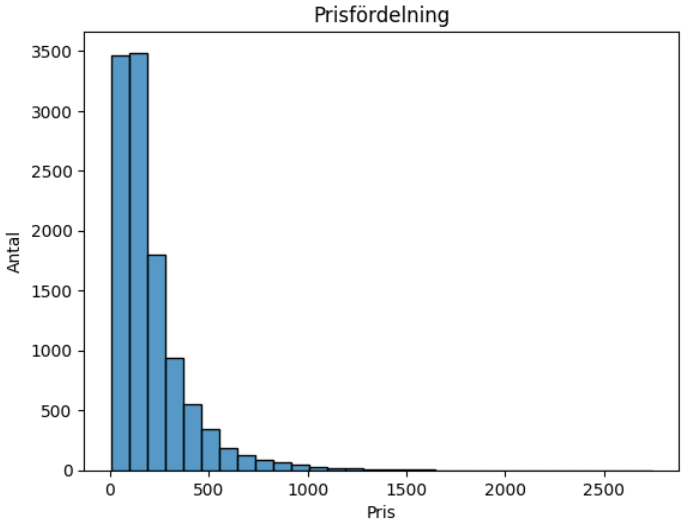

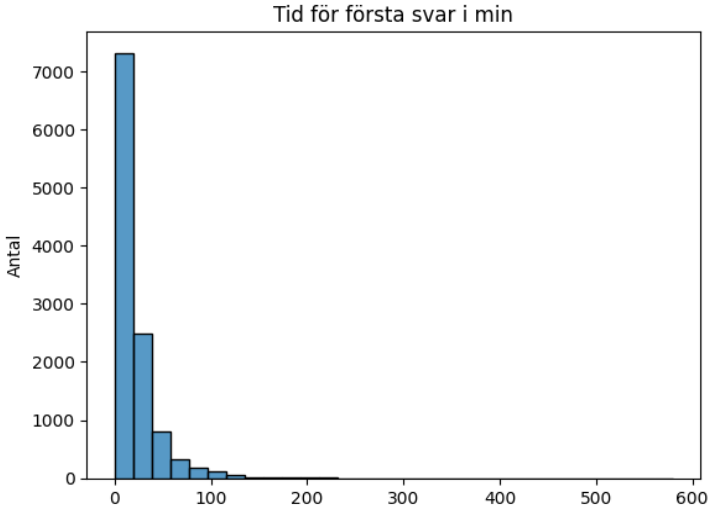

Pipeline och utvärdering

1

Uppdelning i train och test set

2

Transformera features

- Numeriska
- Kategoriska

3

Imputer

- Median stategy
- Most frequent strategy

4

Undvika läckage

- Train/test-split innan modellering.
- Preprocessing i Pipeline på träningsdata.

Modelljämförelse

- Legal/compliance vill inte att oskyldiga drabbas, dvs inte för mycket FP därför väljer vi att optimera på **precision**.
- Modellering med cross validation StratifiedKfolds.
- RandomForest fick högst precision men vi vill också ha en modell som är lätt att förklara. Den modellen hade även mest variation och vi vill ha en som är konsekvent.
- Vi valde LogisticRegression som har något bättre resultat än DecisionTree.

```
LogisticRegression [0.18529412 0.19303797 0.19783617 0.18389058 0.19593614]
RandomForest [0.6        0.25       0.42857143 0.5        0.5       ]
DecisionTree [0.18556701 0.16842105 0.14       0.16113744 0.19672131]
```

	model	mean	std
1	RandomForest	0.455714	0.116444
0	LogisticRegression	0.191199	0.005624
2	DecisionTree	0.170369	0.019681

```
feature weight
num__prev_reports_30d 0.372510
num__contains_off_platform 0.347079
num__urgency_words 0.259136
num__payment_attempt 0.209646
cat__device_ios 0.097340
```

Viktigaste signalerna i modellen
- flera tidigare rapporter
- kontakt utanför plattformen
- brådskande språk
- betalningsförsök
- vissa tekniska mönster, t.ex. enhetstyp

Ju fler av dessa signaler som finns samtidigt, desto högre risk bedömer modellen.

Beskrivning på enkel svenska till Elin.

Val av modell och tuning

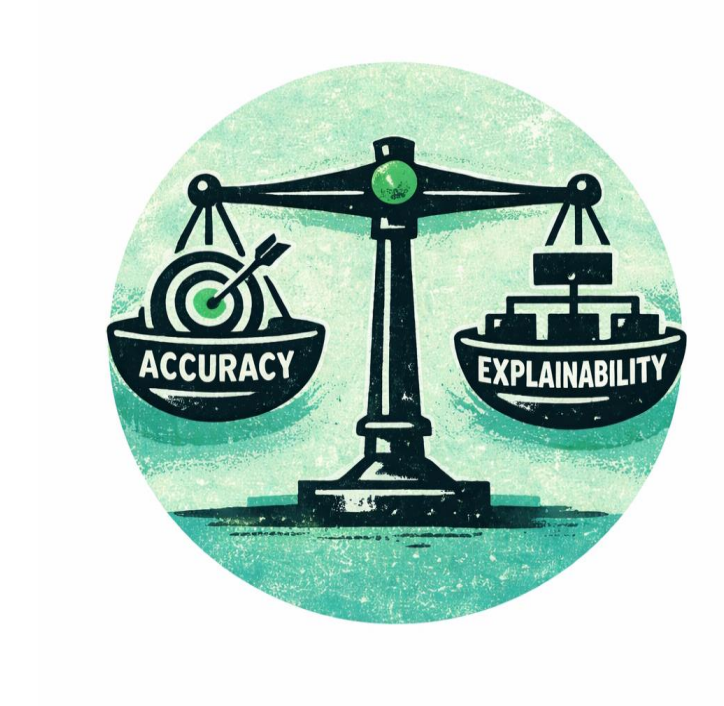

Motivering

Vald modell LogisticRegression som är förklarbar och hade bättre precision.

- Färre FP (falsklarm)
- Beter sig konsekvent

Tuning

GridSearchCV

- Parameter C -> 0,01
- Parameter solver -> lbfgs

Förklaring

Lågt C stark regularisering, stabilare modell, mindre risk för överfitting

Lbfgs effektiv optimeringsmetod med stabilast resultat i CV. Justerar vikterna tills den hittar en bra lösning.

Threshold och konsekvens

False Positives

Legitima annonser kan flaggas som misstänkta.
Eftersom alla flaggningar granskas manuellt leder detta endast till extra kontroll, inte automatiska åtgärder.

False Negatives

Vissa riskfyllda annonser missas av modellen.
Detta är en accepterad kompromiss eftersom modellen prioriterar vad som ska granskas först, inte stoppar allt automatiskt.

Balans & Tröskel

Thresholden valdes för att matcha granskningsteamets kapacitet.
Modellen flaggar cirka 50 av 100 annonser per dag, vilket möjliggör en praktisk balans mellan att hitta riskfall och hålla arbetsbelastningen hanterbar.

Konsekvenser

Modellen fungerar som ett prioriteringsverktyg.
Av cirka 100 annonser flaggas ~50, varav ~9 är faktiska riskfall (TP), medan ~2 missas (FN).

Carina

Prediktion på ny data

- Bästa threshold 0.420 prioriterad utifrån antagandet att teamet hinner granska ca 50 annonser per dag.
- Resultat:
  - relationen antal misstänkta(1)/icke misstänkta(0): 0.5415 / 0.4585
- Av 100 st inlägg per dag tror vår modell att 54.15 är scam och kommer flagga dessa för granskning.
- Antal som enligt fördelningen i testdatan uppskattas kommer vara faktisk scam som modellen hittar (TP) 9.063
- Antal som enligt fördelningen i testdatan uppskattas kommer vara scam som modellen missar (FN) 2.208
- Det är vår uppfattning att detta resulterar i en rimlig arbetsbelastning och bra säkerhet

Risker, begränsningar och nästa steg

- Risker
  - Modellen flaggar även legitima annonser som misstänkta.
  - Alla scamannonser upptäcks inte.
  - Sned, ofullständig data
- Begränsningar
  - Thresholden valdes baserat på träningsdata (via cross-validation), vilket kan ge något optimistiska resultat.
  - Modellen är vald för förklarbarhet, men kan missa mer komplexa samband.
  - Thresholden bygger på antagandet att teamet kan granska t.ex. 50 annonser per dag.
    Om kapaciteten ändras behöver thresholden justeras.
- Nästa steg
  - Testa fler modeller eller kombinera flera modeller (ensembles)
  - Feature engineering
  - Kontinuerligt träna om modellen med ny data för att hantera förändrade scam-mönster.
  - Identifiera fler signaler som bättre fångar riskbeteenden (t.ex. textmönster, användarbeteende).